

**YOLOV26 DAN DYNAMIC ATTENTION UNTUK
DETEKSI IKAN BAWAH AIR DAN KLASIFIKASI
PENYAKIT IKAN TUGAS 2**



Dosen Pengampu:
Prof. Dr.Eng. Fitri Utaminingrum, ST., MT.

Disusun Oleh :

JHONS JANNER SAMUEL .S	245150301111009
MUHAMMAD FADLY NUR HIDAYAT	245150300111050

**PROGRAM STUDI TEKNIK KOMPUTER
FAKULTAS ILMU KOMPUTER
UNIVERSITAS BRAWIJAYA
MALANG**

**KELOMPOK 15
YOLOV26 DAN DYNAMIC
ATTENTION

UNTUK DETEKSI IKAN BAWAH
AIR DAN KLASIFIKASI PENYAKIT
IKAN**

NAMA : JHONS JANNER SAMUEL .S(245150301111009)
TUGAS : Code + Laporan + Datasheet

NAMA: MUHAMMAD FADLY NUR HIDAYAT(245150300111050)
TUGAS: Code +Laporan +Datasheet

1. Latar Belakang dan Tujuan

YOLOComVis dirancang untuk membantu analisis citra ikan secara bertahap. Masalah visual dibagi menjadi tiga keputusan yang saling berhubungan: apakah dan di mana ikan berada, apakah terdapat lesi pada tubuh ikan, dan kondisi atau penyakit apa yang paling mungkin berdasarkan crop ikan.

Pembagian tugas tersebut dipilih agar model klasifikasi tidak langsung menerima seluruh frame yang dapat berisi latar belakang, karang, air, atau objek lain. Pada tahap inferensi, detektor ikan menghasilkan bounding box, crop dari box diteruskan ke detektor lesi dan classifier, lalu seluruh informasi digabungkan menjadi dashboard.

Tujuan eksperimen

1. Menyiapkan dataset dari arsip mentah menjadi struktur yang kompatibel dengan Ultralytics YOLO.
2. Melatih dua model deteksi dan satu model klasifikasi dengan bobot pretrained.
3. Menyimpan grafik loss, precision-recall, mAP, confusion matrix, dan contoh prediksi.
4. Menghasilkan dashboard inferensi sebagai bukti pipeline dapat dijalankan dari input gambar.
5. Menyediakan dokumentasi yang dapat direproduksi melalui notebook Colab dan script lokal.

2. Arsitektur Sistem

Tahap	Masukan	Proses	Keluaran
1. Deteksi ikan	Frame atau foto	YOLO11n detect	Bounding box ikan + confidence
2. Crop	Bounding box ikan	Pemotongan area ikan	Citra ikan terlokalisasi
3. Deteksi lesi	Crop ikan	YOLO11n detect	Bounding box lesi/luka
4. Klasifikasi	Crop ikan	YOLO11n-cl	Top-3 kelas penyakit + probabilitas
5. Dashboard	Semua keluaran	OpenCV compositing	Visualisasi gabungan

Deteksi menggunakan format label YOLO satu kelas. Setiap baris anotasi memiliki bentuk `class_id`, `center_x`, `center_y`, `width`, `height`, dengan koordinat telah dinormalisasi terhadap lebar dan tinggi gambar. Klasifikasi menggunakan struktur folder kelas, sehingga nama folder menjadi label kelas.

```

fish_model =
YOLO('Runs_Baseline/model_ikan/weights/best.pt')
lesion_model =
YOLO('Runs_Baseline/model_lesi/weights/best.pt')
classifier =
YOLO('Runs_Baseline/model_penyakit/weights/best.pt')
result = fish_model(image)[0]
for box in result.bboxes:
    crop = image[y1:y2, x1:x2]

```

```
lesion_result = lesion_model(crop)[0]  
classification = classifier(crop)[0]
```

3. Sumber Data dan Persiapan Dataset

Fish4Knowledge digunakan untuk melatih detektor ikan. Sumber resminya menyediakan 27.370 citra dalam 23 kelompok spesies, sedangkan implementasi repositori menggunakan subset dan menyatukan objek menjadi kelas fish. Jumlah pada sumber resmi tidak digunakan sebagai jumlah gambar yang dilatih pada eksperimen ini.

FishDisease dari Computer Vision Lab, Chonnam National University, digunakan untuk deteksi lesi. Pada implementasi, anotasi kelainan visual disatukan menjadi kelas lesion. Citra asli pada sumber FishDisease dilaporkan memiliki resolusi 2048 × 1536 piksel. Dataset Freshwater Fish Disease Aquaculture in South Asia digunakan untuk klasifikasi kondisi ikan berdasarkan folder kelas. Resolusi citra Fish4Knowledge dan Freshwater Fish Disease tidak dinyatakan sebagai satu ukuran tetap karena file sumber memiliki karakteristik yang bervariasi. Pada proses training, kedua detektor menggunakan ukuran masukan 640 piksel, sedangkan classifier menggunakan ukuran masukan 224 piksel.

Dataset	Tujuan	Train	Val	Keterangan
Fish4Knowledge	Deteksi ikan	5.374 gambar / 9.690 objek	6.728 gambar / 2.422 objek	1 kelas: fish
FishDisease	Deteksi lesi	929 gambar / 1.705 objek	226 gambar / 441 objek	1 kelas: lesion

Freshwater Kaggle	Klasifikasi penyakit	1.750 gambar	700 gambar	7 kelas, masing-masing seimbang
-------------------	----------------------	--------------	------------	---------------------------------

3.1 Konversi Fish4Knowledge

Fungsi `prepare_fish_dataset` mengosongkan folder split keluaran, membangun indeks gambar berdasarkan stem nama file, membaca mask grayscale, mencari kontur eksternal terbesar, lalu mengubah bounding rectangle kontur menjadi satu baris label YOLO kelas 0. Pasangan gambar-label diacak dengan seed 42; 20% pasangan dipindahkan ke validation.

```
contours, _ = cv2.findContours(mask,  
cv2.RETR_EXTERNAL, cv2.CHAIN_APPROX_SIMPLE)  
x, y, box_width, box_height =  
cv2.boundingRect(max(contours,  
key=cv2.contourArea))  
label = f"0 {(x + box_width / 2) / width:.6f}  
..."  
random.Random(seed).shuffle(pairs)
```

3.2 Konversi FishDisease

Fungsi `prepare_lesion_dataset` membaca seluruh JSON anotasi, mengambil array annotations, mencari gambar berdasarkan field image atau folder halaman, memuat ukuran gambar, melakukan clipping bounding box ke batas citra, menolak box kosong, kemudian menulis koordinat ter-normalisasi ke label YOLO. Nama keluaran diberi prefix folder halaman agar tidak terjadi benturan nama file.

```
x_min, y_min, x_max, y_max = map(float, bbox)  
x_min, x_max = sorted((max(0.0, x_min),  
min(float(width), x_max)))  
y_min, y_max = sorted((max(0.0, y_min),
```

```
min(float(height), y_max)))  
yolo_lines.append(f"0 {(x_min + x_max) / 2}  
/ width:.6f} ...")
```

3.3 Konversi Dataset Klasifikasi

Fungsi `prepare_classification_dataset` memakai `splitfolders.ratio` dengan rasio 80:20 dan seed 42. Setiap subfolder penyakit dipertahankan sebagai nama kelas. Pada artefak lokal, terdapat tujuh kelas dengan 250 citra train dan 100 citra validation per kelas.

3.4 Validasi Struktur

Fungsi `dataset_summary` menghitung jumlah gambar, label, objek, serta pasangan yang tidak cocok. Ringkasan yang sama dapat diekspor ke JSON, CSV, dan Markdown melalui `save_dataset_report`. Pemeriksaan ini penting karena gambar tanpa label atau label tanpa gambar akan menghasilkan data training yang tidak sesuai harapan.

4. Implementasi Kode

Implementasi utama berada pada `all_in_one_yolocomvis.py`. Script tersebut memusatkan persiapan data, pembuatan YAML, training, evaluasi, pembuatan plot, dashboard, dan ekspor artefak. Script training sederhana pada `scripts/3_training_all.py` menunjukkan tiga pemanggilan `model.train` yang digunakan pada baseline awal.

4.1 Fungsi utilitas

- `image_files`: mengembalikan file gambar dengan ekstensi yang didukung.
- `dataset_summary`: menghitung statistik split dan kecocokan gambar-label.
- `save_dataset_report`: menulis `dataset_summary.json`, `dataset_summary.csv`, dan `dataset_summary.md`.

- `write_dataset_yaml`: membuat YAML portable untuk deteksi ikan dan lesi.
- `metric_value`: mengambil metrik dari object hasil Ultralytics dengan beberapa nama atribut alternatif.

4.2 Training

`train_models` membuat tiga model pretrained. Dua detector memakai `yolo11n.pt`, `imgsz 640`, dan `10 epoch`. Classifier memakai `yolo11n-cls.pt`, `imgsz 224`, dan `10 epoch`. Semua hasil diarahkan ke project `Runs_Baseline` dengan nama model `model_ikan`, `model_lesi`, dan `model_penyakit`.

```
YOLO('yolo11n.pt').train(data=fish_yaml,  
epochs=10, imgsz=640,  
project='Runs_Baseline', name='model_ikan')  
YOLO('yolo11n.pt').train(data=lesion_yaml,  
epochs=10, imgsz=640,  
project='Runs_Baseline', name='model_lesi')  
  
YOLO('yolo11n-cls.pt').train(data=classification_dir,  
epochs=10, imgsz=224,  
project='Runs_Baseline',  
name='model_penyakit')
```

4.3 Evaluasi dan ekspor metrik

`evaluate_models` memuat `best.pt`, menjalankan `model.val`, dan menyimpan `precision`, `recall`, `mAP50`, `mAP50-95` untuk deteksi atau `Top-1` dan `Top-5` untuk klasifikasi. `plot_training_curves` membaca `results.csv` dan membangun grafik gabungan `loss` serta metrik. `classification_confusion_matrix` melakukan prediksi satu per satu pada folder `validation` lalu mengisi matriks aktual versus prediksi.

4.4 Dashboard

run_dashboard membaca satu gambar, menjalankan detektor ikan, memotong setiap ikan, menjalankan detector lesi pada crop, lalu menjalankan classifier. Bounding box ikan diberi warna kuning, lesi merah, sedangkan panel kanan berisi confidence ikan, jumlah lesi, dan tiga prediksi penyakit teratas.

4.5 Penjelasan Script Tahap demi Tahap

Selain pipeline terpadu, proyek menyediakan empat script eksplisit yang memperlihatkan proses eksperimen secara berurutan. Bagian ini menjelaskan kode asli pada folder scripts, bukan hanya versi fungsi yang sudah dirapikan di all_in_one_yolocomvis.py.

4.5.1 scripts/1_proses_fish4knowledge.py

Script ini menyiapkan dataset deteksi ikan dari mask Fish4Knowledge. Mask adalah citra grayscale yang menunjukkan area ikan. Script mengubah area tersebut menjadi bounding box dan label YOLO, kemudian memindahkan 20% pasangan gambar-label ke folder validation.

Bagian import memanggil OpenCV untuk membaca mask, os dan glob untuk mengelola path serta mencari file, shutil untuk memindahkan file, dan random untuk mengambil sampel validation. Enam variabel folder memisahkan sumber mask, gambar train, label train, gambar val, dan label val. os.makedirs(..., exist_ok=True) memastikan folder tujuan tersedia sebelum proses dimulai.

```
mask = cv2.imread(path_mask,
cv2.IMREAD_GRAYSCALE)
tinggi, lebar = mask.shape
contours, _ = cv2.findContours(mask,
cv2.RETR_EXTERNAL, cv2.CHAIN_APPROX_SIMPLE)
```

```
c = max(contours, key=cv2.contourArea)
x, y, w, h = cv2.boundingRect(c)
```

Loop pertama membaca setiap PNG pada folder mask. cv2.IMREAD_GRAYSCALE menghasilkan mask satu kanal. cv2.findContours mencari batas objek; RETR_EXTERNAL hanya mengambil kontur luar, sehingga bagian internal tidak dianggap sebagai objek terpisah. max(..., key=cv2.contourArea) memilih kontur terbesar, lalu cv2.boundingRect mengubah kontur menjadi koordinat x, y, lebar, dan tinggi bounding box.

```
x_center, y_center = (x + w/2) / lebar, (y +
h/2) / tinggi
f.write(f"0 {x_center} {y_center} {w/lebar}
{h/tinggi}\n")
```

Empat nilai koordinat dibagi ukuran gambar agar berubah dari piksel menjadi rentang 0 sampai 1 sesuai format YOLO: titik tengah x, titik tengah y, lebar box, dan tinggi box. Angka 0 di awal baris adalah class_id karena dataset ini hanya memiliki satu kelas, yaitu fish. Nama mask_ diubah menjadi fish_ agar nama label dapat dipasangkan dengan gambar.

```
semua_label = [f for f in
os.listdir(folder_lbl_train) if
f.endswith('.txt')]
val_labels = random.sample(semua_label,
int(len(semua_label) * 0.2))
shutil.move(label_train, label_val)
shutil.move(image_train, image_val)
```

Bagian kedua mengambil sampel acak 20% dari label train. Setiap label dipindahkan ke labels/val dan gambar dengan stem yang sama dipindahkan ke images/val. Dengan demikian, label dan gambar tetap berpasangan. Script ini belum menetapkan random seed, sehingga pembagian dapat berbeda setiap kali dijalankan; pipeline terpadu memperbaikinya dengan seed 42.

Output script adalah file .txt berformat YOLO, gambar pada images/train dan images/val, serta ringkasan terminal bahwa Fish4Knowledge siap digunakan untuk training. Risiko utama versi script ini adalah asumsi ekstensi gambar .png dan kecocokan langsung nama fish_*.txt dengan fish_*.png.

4.5.2 scripts/2_proses_fishdisease.py

Script ini mengubah anotasi mentah FishDisease berbentuk JSON menjadi dataset deteksi lesi berformat YOLO. Setiap JSON dapat memiliki beberapa anotasi bbox, sehingga satu file label dapat berisi beberapa baris objek lesi.

Pada awal script, dir_mentah menunjuk folder sumber, sedangkan empat variabel tujuan memisahkan images/train, images/val, labels/train, dan labels/val. glob(..., recursive=True) memindai JSON pada seluruh subfolder page. Counter sukses, skip_kosong, skip_gambar, dan skip_tanpa_bbox dipakai untuk merangkum kualitas proses.

```
data = json.load(f)
if "annotations" not in data or not
data["annotations"]:
    skip_kosong += 1
    continue
```

```
path_gambar_asli = os.path.join(dir_mentah,  
data["image"])
```

Setiap JSON dibaca menggunakan `json.load`. JSON tanpa annotations dilewati karena tidak memiliki target training. Field image dicoba terlebih dahulu untuk menemukan gambar asli. Jika path tersebut tidak cocok dengan struktur arsip, script menggunakan fallback: mengambil folder page dari lokasi JSON lalu mencari file JPG atau PNG pertama pada folder tersebut.

```
tinggi_img, lebar_img, _ = img.shape  
for ann in data["annotations"]:  
    x_min, y_min, x_max, y_max = ann["bbox"]  
    x_center = ((x_min + x_max) / 2.0) /  
    lebar_img  
    y_center = ((y_min + y_max) / 2.0) /  
    tinggi_img  
    w = (x_max - x_min) / lebar_img  
    h = (y_max - y_min) / tinggi_img  
    baris_yolo.append(f"0 {x_center}  
{y_center} {w} {h}")
```

Ukuran gambar diambil dari `img.shape`. Setiap bbox mentah diasumsikan berbentuk `x_min, y_min, x_max, y_max`, lalu diubah ke format YOLO center-x, center-y, width, height dan dinormalisasi terhadap lebar serta tinggi gambar. Class_id selalu 0 karena semua anotasi diperlakukan sebagai kelas lesion. Berbeda dari script pertama, satu gambar dapat menghasilkan banyak baris label.

```
nama_unik =  
f"{nama_page}_{os.path.splitext(nama_file_asl  
i)[0]}"  
is_val = random.random() < 0.2  
shutil.copy(path_gambar_asli,  
os.path.join(tujuan_img, ...))  
with open(os.path.join(tujuan_lbl,  
f"{nama_unik}.txt"), 'w') as f:  
    f.write("\n".join(baris_yolo))
```

Nama unik menggabungkan nama page dan nama gambar untuk mencegah tabrakan file seperti page10_img1 dan page11_img1. `random.random() < 0.2` memilih validation dengan peluang 20%. Gambar disalin, sedangkan label baru ditulis pada folder yang sesuai. try-except menjaga agar satu JSON yang rusak tidak menghentikan pemrosesan seluruh dataset.

Output script adalah pasangan gambar-label FishDisease, serta jumlah data berhasil dan jumlah data yang dilewati. Pipeline terpadu menambahkan clipping bbox ke batas citra dan penggunaan `Random(seed)` agar pembagian lebih reproducible.

4.5.3 scripts/3_training_all.py

Script ini adalah entry point training baseline. Tidak ada preprocessing di dalamnya; script mengasumsikan data sudah disiapkan dan YAML atau folder klasifikasi sudah tersedia. Tiga blok training dijalankan berurutan.

```
from ultralytics import YOLO  
model_ikan = YOLO("yolo11n.pt")  
  
model_ikan.train(data="D:/yolocovis/data_ika
```

```
n.yaml", epochs=10, imgsz=640,  
project="Runs_Baseline", name="model_ikan")
```

YOLO("yolo11n.pt") memuat bobot pretrained YOLO11n untuk task deteksi. Pemanggilan train menerima YAML yang mendefinisikan path dataset, melatih selama 10 epoch dengan ukuran input 640 x 640, dan menyimpan hasil ke Runs_Baseline/model_ikan. Ultralytics otomatis menyimpan best.pt, last.pt, results.csv, args.yaml, grafik, confusion matrix, dan contoh batch.

```
model_lesi = YOLO("yolo11n.pt")  
  
model_lesi.train(data="D:/yolocomvis/data_les  
i.yaml", epochs=10, imgsz=640,  
project="Runs_Baseline", name="model_lesi")  
model_penyakit = YOLO("yolo11n-cls.pt")  
  
model_penyakit.train(data="D:/yolocomvis/data  
sets/freshwater_kaggle", epochs=10,  
imgsz=224, project="Runs_Baseline",  
name="model_penyakit")
```

Blok kedua menggunakan arsitektur deteksi yang sama untuk lesi, tetapi membaca data_lesi.yaml dan menyimpan ke model_lesi. Blok ketiga menggunakan yolo11n-cls.pt; akhiran -cls penting karena task-nya klasifikasi, bukan bounding-box detection. Parameter data langsung menunjuk folder freshwater_kaggle karena Ultralytics membaca subfolder kelas train dan val. Ukuran input classifier 224 x 224 berbeda dari detector karena mengikuti konfigurasi klasifikasi.

Output script berupa tiga folder hasil eksperimen dan checkpoint model. results.csv menjadi sumber tabel metrik per epoch pada laporan ini. Perlu diperhatikan bahwa path pada script bersifat absolut Windows, sehingga perlu disesuaikan ketika dijalankan di komputer atau Colab lain. Pada artefak model_lesi, args.yaml menunjukkan resume dari last.pt; fakta tersebut dicatat sebagai bagian dari riwayat eksperimen.

4.5.4 scripts/4_tes_pipeline_final.py

Script ini menguji pipeline end-to-end menggunakan tiga best checkpoint. Berbeda dari training, script ini tidak mengubah bobot; tugasnya adalah membaca satu gambar, menemukan ikan, menjalankan analisis lesi dan klasifikasi pada setiap crop ikan, lalu menyusun dashboard visual.

```
deteksi_ikan = YOLO(path_ikan)
deteksi_lesi = YOLO(path_lesi)
klasifikasi = YOLO(path_penyakit)
gambar = cv2.imread(path_gambar_tes)
img_h, img_w = gambar.shape[:2]
canvas = np.zeros((canvas_h, img_w +
panel_w, 3), dtype=np.uint8)
canvas[0:img_h, 0:img_w] = gambar
```

Tiga model dimuat dari best.pt. cv2.imread membaca gambar uji; apabila hasilnya None, script menghentikan proses dengan pesan error. Canvas baru dibuat lebih lebar dari gambar asli agar memiliki panel informasi di sisi kanan. Warna panel dan box ditetapkan dalam format BGR OpenCV: ikan cyan/kuning, lesi merah, dan teks putih atau abu-abu.

```
hasil_ikan = deteksi_ikan(gambar)[0]
for kotak in hasil_ikan.bboxes:
    x1, y1, x2, y2 = map(int, kotak.xyxy[0])
    conf_ikan = float(kotak.conf[0]) * 100
    potongan_ikan = gambar[y1:y2, x1:x2]
    hasil_lesi =
deteksi_lesi(potongan_ikan)[0]
    hasil_klasifikasi =
klasifikasi(potongan_ikan)[0]
```

Prediksi deteksi ikan diambil dari hasil_ikan.bboxes. Koordinat xyxy diubah menjadi integer untuk menggambar rectangle dan melakukan slicing array. Confidence dikalikan 100 agar tampil sebagai persen. Crop ikan diproses ulang oleh detector lesi dan classifier, sehingga lesi dan penyakit dinilai pada area ikan, bukan seluruh frame.

```
for luka in hasil_lesi.bboxes:
    lx1, ly1, lx2, ly2 = map(int,
luka.xyxy[0])
    cv2.rectangle(canvas, (x1 + lx1, y1 +
ly1), (x1 + lx2, y1 + ly2), COLOR_BOX_LESI,
2)
    top5_indices = hasil_klasifikasi.probs.top5
    top_probs =
[float(hasil_klasifikasi.probs.data[i]) * 100
for i in top5_indices]
```

Koordinat lesi awalnya relatif terhadap crop. Penambahan x1 dan y1 mengembalikannya ke koordinat canvas global. Classifier menyediakan indeks Top-5 dan probabilitas; dashboard hanya menampilkan tiga teratas melalui range(3), lengkap dengan progress bar yang panjangnya sebanding dengan probabilitas.

```
cv2.imwrite(path_simpan, canvas)
cv2.imshow("Hasil Analisis YOLOv26", canvas)
cv2.waitKey(0)
cv2.destroyAllWindows()
```

Canvas disimpan sebagai hasil_dashboard_baseline.jpg, kemudian ditampilkan pada jendela OpenCV. cv2.waitKey(0) menahan program sampai tombol ditekan dan cv2.destroyAllWindows menutup jendela dengan bersih. Karena script ini menggunakan GUI, cv2.imshow dapat gagal pada runtime headless seperti Colab; untuk lingkungan tersebut, bagian simpan dengan cv2.imwrite tetap dapat dipakai tanpa pop-up.

Alur uji pipeline dapat diringkas sebagai: gambar penuh -> deteksi ikan -> crop tiap ikan -> deteksi lesi dan klasifikasi -> gambar box serta panel informasi -> simpan dashboard. Catatan pada panel mengenai false positive warna merupakan interpretasi keterbatasan baseline, bukan hasil metrik tambahan.

5. Konfigurasi Eksperimen

Parameter	Deteksi ikan	Deteksi lesi	Klasifikasi
Model	yolo11n.pt	yolo11n.pt	yolo11n-cls.pt
Epoch	10	10	10
Image size	640	640	224
Batch	16	16	16
Optimizer	auto	auto	auto
Learning rate awal	0,01	0,01	0,01
Weight decay	0,0005	0,0005	0,0005

Augmentasi utama	mosaic, flip LR, randaugment	mosaic, flip LR, randaugment	flip LR, randaugment, erasing
------------------	------------------------------	------------------------------	-------------------------------

args.yaml aktual menunjukkan seed Ultralytics bernilai 0 dan deterministic true, sedangkan pembagian dataset menggunakan seed 42 pada pipeline persiapan. Untuk model_lesi, args.yaml menyatakan resume dari last.pt; hal ini perlu dicatat ketika membandingkan percobaan atau mengulang training secara eksak.


6. Hasil Training dan Evaluasi

6.1 Deteksi ikan


Loss box turun dari 0,8066 menjadi 0,4723 dan loss klasifikasi turun dari 1,3337 menjadi 0,2206. Recall validation sangat tinggi sejak awal dan mencapai 0,9996 pada epoch ke-10, tetapi precision berada sekitar 0,36. mAP50 terbaik pada epoch ke-3 sebesar 0,3733, sedangkan nilai akhir mAP50-95 sebesar 0,3379. Ini menandakan model cenderung menangkap objek ikan, namun kualitas ketepatan box dan seleksi prediksi masih terbatas.

Epoch	Box loss	Precision	Recall	mAP50	mAP50-95
1	0.8066	0.3568	0.9670	0.3733	0.3031
2	0.7938	0.3564	0.9905	0.3708	0.3133
3	0.7440	0.3609	0.9831	0.3686	0.3198
4	0.6887	0.3596	0.9992	0.3661	0.3227
5	0.6347	0.3593	0.9988	0.3701	0.3256
6	0.5952	0.3596	0.9992	0.3694	0.3284
7	0.5574	0.3595	0.9992	0.3643	0.3260


8	0.5225	0.3594	0.9988	0.3635	0.3412
9	0.5040	0.3594	0.9992	0.3639	0.3344
10	0.4723	0.3592	0.9996	0.3618	0.3379



Gambar 1. Kurva training dan metrik validasi deteksi ikan.



Gambar 2. Confusion matrix ternormalisasi deteksi ikan.




Gambar 3. Contoh prediksi deteksi ikan pada validation batch.

6.2 Deteksi lesi


Model lesi mengalami peningkatan bertahap: precision dari 0,0036 menjadi 0,6733, mAP50 dari 0,0201 menjadi 0,6264, dan mAP50-95 dari 0,0076 menjadi 0,2968. Recall akhir 0,5646 menunjukkan sebagian lesi masih terlewat. Jarak antara mAP50 dan mAP50-95 memperlihatkan bahwa box sering cukup benar pada threshold IoU 0,50 tetapi belum konsisten ketika syarat IoU diperketat.

Epoch	Box loss	Precision	Recall	mAP50	mAP50-95
1	2.3688	0.0036	0.5533	0.0201	0.0076
2	2.3525	0.3305	0.2698	0.2224	0.0890
3	2.2298	0.4736	0.3810	0.3609	0.1412
4	2.1783	0.4240	0.4195	0.3775	0.1514
5	2.1610	0.5319	0.4717	0.4402	0.1599


6	2.0905	0.5535	0.4785	0.4713	0.1871
7	2.0392	0.5760	0.4867	0.5379	0.2227
8	1.9765	0.7188	0.5147	0.5989	0.2605
9	1.9064	0.6578	0.5714	0.6301	0.2783
10	1.8582	0.6733	0.5646	0.6263	0.2968



Gambar 4. Kurva training dan metrik validasi deteksi lesi.



Gambar 5. Kurva precision-recall deteksi lesi.



Gambar 6. Contoh prediksi lesi pada validation batch.


6.3 Klasifikasi penyakit

Loss train turun dari 1,6408 menjadi 0,1996 dan loss validation turun dari 0,8945 menjadi 0,0285. Top-1 meningkat dari 71,00% menjadi 99,29%, sedangkan Top-5 mencapai 100% mulai epoch ke-4.


Confusion matrix menunjukkan nilai diagonal sekitar 0,98 sampai

1,00, dengan kesalahan kecil antar beberapa kelas penyakit bakteri dan penyakit lainnya.

Epoch	Train loss	Val loss	Top-1	Top-5
1	1.6408	0.8945	71.00%	98.00%
2	0.9915	0.4728	85.71%	99.43%
3	0.7077	0.3268	88.71%	99.71%
4	0.5563	0.2190	93.14%	100.00%
5	0.5171	0.1318	96.00%	100.00%
6	0.4417	0.0746	98.71%	100.00%
7	0.3320	0.0555	99.14%	100.00%
8	0.3034	0.0612	98.57%	100.00%
9	0.2521	0.0505	98.57%	100.00%
10	0.1996	0.0285	99.29%	100.00%



Gambar 7. Kurva loss dan akurasi klasifikasi penyakit.




Gambar 8. Confusion matrix ternormalisasi klasifikasi penyakit.



Gambar 9. Contoh prediksi kelas penyakit pada validation batch.

7. Dokumentasi Inferensi dan Uji Coba

Selain grafik training, repository menyimpan sebelas gambar ujicoba dan satu dashboard baseline. Gambar-gambar tersebut berfungsi sebagai dokumentasi kualitatif: memperlihatkan citra masukan, bounding box ikan, hasil deteksi lesi, serta ranking kelas penyakit. Evaluasi kualitatif tidak menggantikan metrik validation, tetapi membantu menemukan perilaku yang mudah terlewat pada angka agregat.



Gambar 10. Dashboard pipeline baseline dengan deteksi ikan, jumlah lesi, dan Top-3 klasifikasi.

Pada dashboard, kotak kuning merepresentasikan hasil detektor ikan. Crop ikan kemudian dianalisis oleh dua model berikutnya. Panel kanan menampilkan confidence deteksi, jumlah lesi yang ditemukan, dan tiga kelas penyakit teratas. Confidence satu gambar tidak boleh langsung disamakan dengan Top-1 validation karena keduanya dihitung pada konteks data dan prosedur yang berbeda.

8. Keterbatasan dan Rencana Pengembangan

Keterbatasan utama eksperimen terletak pada kualitas pembagian data dan kelengkapan anotasi. Seluruh gambar validasi klasifikasi pada snapshot berulang terhadap train, sedangkan Fish4Knowledge mempunyai ketidaksesuaian pasangan gambar-label dan hubungan tracking ID lintas split. Temuan tersebut membatasi penafsiran angka validasi sebagai kemampuan model pada data baru.

Pipeline terpadu telah menyediakan ringkasan dataset dalam format JSON, CSV, dan Markdown serta membangun ulang pasangan data menggunakan seed 42. Tahap berikutnya adalah menjalankan pipeline tersebut dari data mentah, menyimpan manifest nama berkas, label, sumber kelompok, split, dan hash konten, kemudian melatih ulang ketiga model. Pasangan gambar-label hasil pembangunan ulang juga diperiksa agar gambar tanpa objek yang sah dapat dibedakan dari gambar berobjek yang kehilangan anotasi.

Pembagian train, val, dan test selanjutnya dilakukan setelah pengelompokan duplikasi dan sumber pengambilan. Salinan atau turunan dari citra yang sama ditempatkan dalam satu split. Tracking atau video dapat menjadi dasar pengelompokan Fish4Knowledge, sedangkan identitas individu atau sesi pengambilan digunakan pada FishDisease apabila tersedia. Data test disimpan terpisah dari pemilihan model dan penyesuaian parameter.

Setelah data diperbaiki, model dilatih ulang dan checkpoint terpilih dievaluasi pada test independen. Hasil dilengkapi precision, recall, mAP, metrik klasifikasi per kelas, confusion matrix, dan contoh prediksi benar maupun salah. Versi perangkat lunak, perangkat komputasi, keputusan optimizer, serta riwayat resume dicatat agar eksperimen dapat ditelusuri kembali.

Pengembangan DAM memerlukan eksperimen yang memisahkan pengaruh pergantian arsitektur dari pengaruh attention. Perbandingan yang relevan mencakup YOLO26 tanpa DAM dan YOLO26 dengan DAM pada data, ukuran model, seed, anggaran pelatihan, serta aturan evaluasi yang sebanding. Perbandingan YOLO11 dengan YOLO26 yang ditambah DAM saja belum dapat mengisolasi kontribusi modul. Gagasan attention terhadap skala, lokasi, dan kanal pada Dynamic Head menjadi rujukan konseptual; peningkatan kinerja pada tugas ikan tetap perlu dibuktikan secara eksperimen.

Evaluasi sistem terpadu juga memerlukan citra target dengan anotasi ikan, lesi, dan kondisi yang sesuai. Pengukuran mencakup ikan yang terlewat, kesalahan lokalisasi, kesalahan klasifikasi, serta waktu

pemrosesan seluruh tahap. Klaim kecepatan atau FPS baru dapat dinilai setelah perangkat, ukuran input, batch, dan bagian pipeline yang diukur dilaporkan secara jelas.

9. Kesimpulan

Implementasi menghasilkan alur pengolahan citra yang menghubungkan deteksi ikan, deteksi lesi, dan klasifikasi kondisi ikan menggunakan dua model YOLO11n serta satu YOLO11n-clas. Ketiga model dilatih secara terpisah selama 10 epoch, kemudian diintegrasikan melalui crop ikan pada tahap inferensi. Tahap ini menjadi baseline bagi rancangan YOLO26 dengan Dynamic Attention pada Tugas 1.

Pada epoch ke-10, detektor ikan mencatat precision 35,924%, recall 99,959%, dan mAP50-95 33,793%. Detektor lesi mencatat precision 67,330%, recall 56,463%, dan mAP50-95 29,683%. Classifier mencatat Top-1 accuracy 99,286% pada hasil validasi tersimpan. Nilai-nilai tersebut menggambarkan run yang tersedia, dengan keterbatasan berupa overlap data klasifikasi, ketidaksesuaian anotasi ikan, dan belum tersedianya test independen.

Dengan demikian, capaian utama pada tahap ini adalah penerapan preprocessing, pelatihan, penyimpanan hasil, dan integrasi inferensi dalam Python. Penilaian akhir kemampuan generalisasi serta manfaat DAM masih memerlukan perbaikan data dan eksperimen lanjutan. Keberadaan dashboard menunjukkan contoh keluaran sistem, tetapi belum membuktikan ketepatan diagnosis atau keberhasilan sistem pada seluruh kondisi bawah air.

Daftar Pustaka

[S1] Kelompok 15. *Tugas Comvis Kelompok 15 YOLOv26 Dynamic Attention*. PDF lampiran pengguna, 19 halaman.

[S2] Kelompok 14. *YOLOV26 dan Dynamic Attention PlantVillage Tugas 2*. PDF lampiran pengguna, 21 halaman.

[S3] F4-dly. *comviskan*. Repositori dan inventaris data pada commit yang diperiksa.

<https://github.com/F4-dly/comviskan/tree/a298ebbb070ed953eed99f0295020070478f5727>

[S4] F4-dly. Skrip training tiga model.

https://github.com/F4-dly/comviskan/blob/a298ebbb070ed953eed99f0295020070478f5727/scripts/3_training_all.py

[S5] F4-dly. Skrip preprocessing Fish4Knowledge.

https://github.com/F4-dly/comviskan/blob/a298ebbb070ed953eed99f0295020070478f5727/scripts/1_proses_fish4knowledge.py

[S6] F4-dly. Skrip preprocessing FishDisease.

https://github.com/F4-dly/comviskan/blob/a298ebbb070ed953eed99f0295020070478f5727/scripts/2_proses_fishdisease.py

[S7] F4-dly. Skrip pembagian folder Kaggle.

https://github.com/F4-dly/comviskan/blob/a298ebbb070ed953eed99f0295020070478f5727/scripts/bagi_folder_kaggle.py

[S8] F4-dly. Skrip pipeline inferensi.

https://github.com/F4-dly/comviskan/blob/a298ebbb070ed953eed99f0295020070478f5727/scripts/4_tes_pipeline_final.py

[S9] F4-dly. CSV hasil deteksi ikan.

https://github.com/F4-dly/comviskan/blob/a298ebbb070ed953eed99f0295020070478f5727/runs/detect/Runs_Baseline/model_ikan/results.csv

[S10] F4-dly. CSV hasil deteksi lesi.

https://github.com/F4-dly/comviskan/blob/a298ebbb070ed953eed99f0295020070478f5727/runs/detect/Runs_Baseline/model_lesi/results.csv

[S11] F4-dly. CSV hasil klasifikasi penyakit.
https://github.com/F4-dly/comviskan/blob/a298ebbb070ed953eed99f0295020070478f5727/runs/classify/Runs_Baseline/model_penyakit/results.csv

[S12] Ultralytics. Dokumentasi YOLO11 (<https://docs.ultralytics.com/models/yolo11/>) dan YOLO26 (<https://docs.ultralytics.com/models/yolo26/>). Dai, X., Chen, Y., Xiao, B., Chen, D., Liu, M., Yuan, L., & Zhang, L. (2021). *Dynamic Head: Unifying Object Detection Heads with Attentions*. CVPR, 7373–7382. <https://arxiv.org/abs/2106.08322>

[S13] University of Edinburgh. Fish Recognition Ground Truth Data. <https://homepages.inf.ed.ac.uk/rbf/Fish4Knowledge/GROUNDTRUTH/RECOG/> — Computer Vision Lab, Chonnam National University, FishDisease Dataset. Hwang, S.-B., et al. (2025). *Flatfish lesion detection based on part segmentation approach and lesion image generation*. Journal of the World Aquaculture Society, 56(3), e70031. Data klasifikasi: Biswas, S., Freshwater Fish Disease Aquaculture in South Asia, Kaggle. <https://www.kaggle.com/datasets/subirbiswas19/freshwater-fish-disease-aquaculture-in-south-asia/data>

[S14] Ultralytics. Format dataset deteksi (<https://docs.ultralytics.com/datasets/detect/>), pelatihan model (<https://docs.ultralytics.com/modes/train/>), klasifikasi citra (<https://docs.ultralytics.com/tasks/classify/>).

[S15] scikit-learn. Classification report (https://scikit-learn.org/stable/modules/generated/sklearn.metrics.classification_report.html) dan Common pitfalls and recommended practices (https://scikit-learn.org/stable/common_pitfalls.html).

Lampiran

Github : <https://github.com/F4-dly/comviskan/tree/main>

Colab :  [yolocomis_colab.ipynb](#)