

KELOMPOK 15
YOLOv26 + DYNAMIC
ATTENTION
untuk Deteksi Ikan Bawah Air
dan Klasifikasi Penyakit Ikan

NAMA: JHONS JANNER SAMUEL .S (NIM: 245150301111009)

TUGAS: YOLO dan perkembangan model deteksi objek

NAMA: MUHAMMAD FADLY NUR HIDAYAT (NIM:
245150300111050)

TUGAS: YOLOv26, Dynamic Attention, dan dataset

1.1. YOLO

YOLO (You Only Look Once) adalah keluarga model deep learning untuk object detection yang memproses seluruh citra dalam satu alur feed-forward. Model memprediksi lokasi objek melalui bounding box sekaligus kelas objeknya, sehingga tidak perlu membuat region proposal secara terpisah. Pada model modern, alur YOLO umumnya terdiri atas backbone untuk mengekstraksi fitur, neck untuk menggabungkan fitur dari beberapa skala, dan head untuk menghasilkan prediksi.

Keunggulan utama YOLO adalah kecepatan inferensi dan kemampuannya memproses video secara mendekati real time. Namun, deteksi ikan bawah air memiliki tantangan berupa pencahayaan tidak merata, warna yang berubah akibat air, gelembung, pantulan, background yang ramai, occlusion, serta ukuran ikan atau gejala penyakit yang kecil. Karena itu, perkembangan YOLO tidak hanya mengejar akurasi, tetapi juga efisiensi komputasi, deteksi objek kecil, kemudahan deployment, dan kemampuan menangkap fitur penting.

Dalam tabel berikut, versi yang ditampilkan adalah tonggak utama dalam perkembangan YOLO. Tidak semua versi berasal dari pengembang yang sama; penamaan YOLO juga digunakan oleh beberapa proyek open source. YOLOv26 pada dokumen ini mengikuti nama resmi Ultralytics, yaitu YOLO26 tanpa huruf v.

Tabel 1.1. Perkembangan utama model YOLO

Versi	Tahun	Pembeda utama	Dampak / relevansi
YOLOv1	2016	One-stage berbasis grid; prediksi box dan kelas dalam satu pass.	Sangat cepat, tetapi masih lemah pada objek kecil dan objek yang berdekatan.
YOLOv2 / 9000	2017	Anchor box, batch normalization, high-resolution classifier, dan multi-scale training.	Lokalisasi dan generalisasi meningkat; dapat mengenali lebih banyak kelas.
YOLOv3	2018	Backbone Darknet-53 dan prediksi pada tiga skala.	Lebih baik untuk objek kecil dan deteksi multi-skala.
YOLOv4	2020	CSPDarknet53, PANet, SPP, Mosaic augmentation, Mish, dan CloU.	Meningkatkan trade-off speed-accuracy pada GPU umum.
YOLOv5	2020	Implementasi Ultralytics berbasis PyTorch, CSP/PAN, AutoAnchor, dan pipeline praktis.	Mudah dilatih, dikustomisasi, dan diekspor ke berbagai format.
YOLOv6	2022	EfficientRep, Rep-PAN, decoupled head, dan orientasi deployment industri.	Menargetkan efisiensi serta throughput tinggi pada perangkat produksi.
YOLOv7	2022/2023	E-ELAN, model scaling, auxiliary head, dan trainable bag-of-freebies.	Mendorong batas akurasi dan kecepatan detektor real time.
YOLOv8	2023	C2f, anchor-free split head, dan dukungan multi-task.	Training custom dataset lebih sederhana dan fleksibel.
YOLOv9	2024	GELAN dan Programmable Gradient Information (PGI).	Mengurangi kehilangan informasi dan memperbaiki aliran gradien.
YOLOv10	2024	Consistent dual assignments dan end-to-end NMS-free detection.	Mengurangi ketergantungan pada post-processing NMS dan latensi.
YOLO11	2024	Backbone/neck yang diperbaiki dan efisiensi parameter; mendukung banyak task.	Menyeimbangkan akurasi, ukuran model, dan kemudahan deployment.
YOLO12	2025	Attention-centric architecture, Area Attention, dan R-ELAN.	Memakai konteks global lebih kuat, tetapi dapat lebih berat pada memori.
YOLO26	2026	Dual head, DFL-free regression, STAL, Progressive Loss, dan MuSGD.	Fokus pada end-to-end inference, objek kecil, dan deployment edge; menjadi basis penelitian kelompok 15.

Sumber: disusun oleh penulis berdasarkan Redmon et al. (2016), Redmon and Farhadi (2017, 2018), Bochkovskiy et al. (2020), Li et al. (2022), Wang et al. (2023, 2024a, 2024b), dan Ultralytics (2020, 2023, 2024, 2025, 2026).

1.2. YOLOv26 (YOLO26)


YOLO26 adalah keluarga model visi real time dari Ultralytics yang dirilis pada 2026. Nama resminya ditulis YOLO26, tetapi pada judul tugas digunakan YOLOv26 agar konsisten dengan penamaan tugas kelompok. Model ini tersedia dalam ukuran nano, small, medium, large, dan extra large, serta mendukung object detection, image classification, instance segmentation, semantic segmentation, pose estimation, depth estimation, dan oriented object detection.

- Dual-head architecture: one-to-one head menjadi jalur default end-to-end tanpa NMS, sedangkan one-to-many head dapat dipakai bila akurasi maksimum dan NMS masih dapat ditoleransi.
- DFL-free regression: Distribution Focal Loss dihilangkan dari head deteksi sehingga regresi box menjadi lebih sederhana dan lebih mudah diekspor.
- STAL (Small-Target-Aware Label Assignment): menjaga cakupan label positif untuk objek kecil, sesuai dengan ikan yang terlihat kecil atau jauh pada video bawah air.
- Progressive Loss: bobot pelatihan secara bertahap mengalihkan fokus dari head one-to-many menuju head one-to-one agar tujuan training sesuai dengan inferensi.
- MuSGD: optimizer hibrida Muon dan SGD yang ditujukan untuk membuat proses training lebih stabil dan efisien.
- Edge-oriented deployment: jalur prediksi yang lebih sederhana dapat membantu implementasi pada CPU, kamera, atau perangkat edge.

Kaitan dengan judul kelompok: YOLO26 menjadi model dasar, sedangkan Dynamic Attention menjadi modul tambahan yang dirancang untuk memperkuat fitur ikan dan gejala penyakit. Dynamic Attention bukan komponen bawaan yang harus diklaim sebagai fitur asli YOLO26. Penelitian dapat membandingkan YOLO26 baseline dengan YOLO26 + Dynamic Attention menggunakan pembagian data dan konfigurasi training yang sama.

1.2.1. Arsitektur YOLO26

Secara makro, YOLO26 menerima citra, mengekstraksi fitur bertingkat melalui backbone, menggabungkan fitur pada neck, lalu meneruskannya ke head deteksi. Pada rancangan kelompok 15, Dynamic Attention ditempatkan pada neck setelah proses fusi fitur agar model dapat memberi bobot berbeda pada kanal, lokasi, dan level fitur sesuai isi citra.



Sumber: disusun oleh penulis berdasarkan Jocher et al. (2026) dan Ultralytics (2026); posisi Dynamic Attention merupakan rancangan usulan.

Gambar 1.1. Arsitektur YOLO26 dengan integrasi Dynamic Attention

Tabel 1.2. Bagian arsitektur YOLO26 dan fungsinya

Bagian	Fungsi pada penelitian
Input dan preprocessing	Resize, normalisasi, dan augmentasi citra ikan. Untuk video, frame dapat diambil dari Fish4Knowledge.
Backbone	Mengekstraksi fitur rendah sampai tinggi seperti tepi, tekstur, bentuk ikan, dan pola warna.
Neck / feature fusion	Menggabungkan fitur multi-skala agar ikan berukuran kecil dan besar sama-sama dapat dipelajari.
Dynamic Attention	Modul usulan yang memberi bobot adaptif pada level, kanal, dan lokasi fitur sebelum masuk ke head.
One-to-one head	Menghasilkan prediksi end-to-end tanpa NMS pada jalur default YOLO26.
One-to-many head	Menyediakan prediksi dense sebagai pilihan alternatif dengan post-processing NMS.
Training components	STAL, Progressive Loss, dan MuSGD membantu assignment objek kecil, pembobotan loss, dan optimasi.

Bagian	Fungsi pada penelitian
Output	Bounding box, kelas objek, dan confidence; untuk klasifikasi, output berupa kelas penyakit sesuai dataset yang digunakan.

Pada eksperimen klasifikasi penyakit, backbone dan Dynamic Attention dapat diteruskan ke YOLO26-clc. Pada eksperimen deteksi area lesi, setiap lesi harus memiliki bounding box atau mask. Label penyakit yang hanya berada pada tingkat gambar belum cukup untuk mengukur ketepatan lokasi lesi.

1.3. Dynamic Attention

Attention mechanism membantu jaringan memilih fitur yang lebih informatif. Jika convolution biasa memproses semua kanal dan lokasi dengan pola bobot yang sama, attention memberikan penguatan atau pelemahan berdasarkan konteks fitur. Istilah dynamic berarti bobot perhatian dihitung dari feature map masukan, sehingga dapat berubah ketika citra berubah.


Pada citra ikan bawah air, area yang penting dapat berupa bentuk tubuh dan sirip, sedangkan area yang mengganggu dapat berupa pasir, tanaman air, gelembung, pantulan, atau perubahan warna karena kedalaman. Pada citra penyakit, gejala seperti bercak, luka, perubahan warna, atau pertumbuhan pada permukaan tubuh sering berukuran kecil. Dynamic Attention diharapkan membantu model mempertahankan fitur tersebut sebelum prediksi dilakukan.

Rancangan modul pada tugas ini mengambil gagasan dari Dynamic Head oleh Dai et al. (2021), yang memandang attention melalui tiga dimensi: scale awareness antar-level fitur, spatial awareness antar-lokasi, dan task/channel awareness di dalam kanal keluaran. Implementasi kelompok 15 disebut Dynamic Attention Module (DAM) dan merupakan adaptasi yang diusulkan untuk YOLO26, bukan klaim bahwa YOLO26 asli sudah memiliki modul DAM ini.

1.3.1. Arsitektur Dynamic Attention

DAM menerima feature maps P3, P4, dan P5 dari neck. Ketiga

level tersebut membawa informasi dengan resolusi dan receptive field yang berbeda. DAM menghitung bobot perhatian dari feature map saat ini, lalu melakukan fusi residual agar fitur asli tidak hilang sepenuhnya.



Bobot perhatian dihitung dari fitur masukan, sehingga berubah mengikuti kondisi citra.

Sumber: disusun oleh penulis berdasarkan konsep Dynamic Head Dai et al. (2021); rancangan DAM disesuaikan dengan kebutuhan citra ikan.

Gambar 1.2. Rancangan Dynamic Attention Module

1. Input feature maps: mengambil P3, P4, dan P5 dari neck YOLO26 agar informasi objek kecil, sedang, dan besar dapat diproses bersama.
2. Scale attention: menghitung bobot untuk setiap level fitur. Level dengan informasi paling relevan untuk ukuran objek tertentu memperoleh bobot lebih besar.
3. Channel/task attention: memakai ringkasan global, misalnya global average pooling dan MLP atau 1x1 convolution, untuk memilih kanal yang membawa informasi warna, tekstur, atau bentuk.
4. Spatial attention: memetakan lokasi yang lebih penting melalui pooling sepanjang kanal dan convolution, sehingga area tubuh ikan atau lesi lebih diprioritaskan daripada background.
5. Adaptive fusion dan residual: mengalikan bobot attention dengan feature map lalu menambahkannya kembali ke fitur asli agar proses belajar tetap stabil.

6. Output: fitur yang telah diperkuat diteruskan ke head YOLO26 atau ke classifier YOLO26-cls.

Secara sederhana, untuk level fitur l dapat ditulis $F_{\text{hat}_l} = F_l + \gamma \times A_{\text{scale}_l} \times A_{\text{channel}_l} \times A_{\text{spatial}_l} \times F_l$. Nilai A dihitung dari fitur masukan menggunakan sigmoid atau softmax, sedangkan γ dapat digunakan sebagai pengali residual yang dipelajari. Pengujian sebaiknya membandingkan baseline tanpa DAM, DAM kanal saja, DAM kanal-spasial, dan DAM lengkap.

1.4. Dataset

Dataset yang digunakan memiliki peran berbeda dan tidak boleh langsung digabung sebagai satu daftar kelas. Fish4Knowledge menyediakan variasi visual ikan pada lingkungan bawah air untuk deteksi ikan. FishDisease/FlatIMG menyediakan anotasi lesi dan label patogen untuk deteksi area lesi. Dataset Freshwater Fish Disease dari Kaggle menyediakan label penyakit pada tingkat citra untuk klasifikasi. Pembagian ini membuat YOLO26 + Dynamic Attention dapat diuji sesuai jenis anotasinya dan mencegah label penyakit tingkat gambar disalahartikan sebagai lokasi lesi.

Tabel 1.3. Dataset dan perannya dalam penelitian

Dataset	Isi data	Label / anotasi	Peran	Keterbatasan
Fish4Knowledge	27.370 citra ikan terverifikasi; 23 cluster spesies; image dan mask terpisah.	Label spesies, mask, tracking ID, dan fish ID.	Deteksi/lokalisasi ikan bawah air; kelas keluaran dapat dibuat sebagai fish.	Tidak memiliki label penyakit; sangat tidak seimbang.
FishDisease / FlatIMG	1.861 foto terkait lesi; 164 flatfish; 394 kasus lesi unik; resolusi foto asli 2048 x 1536.	Bounding box lesi, lokasi lesi, dan label patogen multi-label.	Deteksi lesi dengan YOLO26 + DAM; label patogen untuk analisis multilabel.	Ada citra generasi dan background removal; perlu dipisahkan saat evaluasi.
Freshwater Fish Disease (Kaggle)	Versi 4: 2.451 file; 7 kelas; deskripsi halaman menyebut 250 citra per kelas.	Label penyakit pada tingkat citra/folder atau CSV; tidak ada bounding box yang dijelaskan.	Klasifikasi multi-kelas menggunakan YOLO26-cls + DAM pada citra/crop ikan.	Jumlah file ringkasan berbeda dari 7 x 250; resolusi tidak ditulis di data card.

1.4.1. Rincian datasheet dataset

Rincian berikut disusun dari laman resmi dataset dan publikasi yang dirujuk oleh laman tersebut. Angka pada dataset yang memiliki beberapa jenis anotasi dijelaskan berdasarkan unitnya, misalnya jumlah citra, jumlah kasus lesi, jumlah instance label, atau jumlah record positif. Dengan demikian, angka multi-label tidak dibaca sebagai jumlah kelas tunggal.

1.4.2. Fish4Knowledge — deteksi ikan bawah air

Link dataset:

<https://homepages.inf.ed.ac.uk/rbf/Fish4Knowledge/GROUNDTRUTH/RECOG/>.

Dataset ini berasal dari video bawah air dan menyediakan 27.370 citra ikan terverifikasi dalam 23 cluster spesies. Resolusi: tidak seragam dan tidak dicantumkan sebagai satu ukuran tetap pada laman ground-truth; citra dan mask disimpan pada paket yang berbeda. Nama file memuat tracking ID dan fish ID, sehingga citra dengan tracking ID sama berasal dari trajectory yang sama.

Tabel 1.4. Kelas Fish4Knowledge dan jumlah deteksi

Kelas / cluster	Jumlah citra Detection #	Trajectory #	Penjelasan kelas
01. Dascyllus reticulatus	12.112	4.240	Cluster spesies; label manual.
02. Plectroglyphidodon dickii	2.683	1.225	Cluster spesies; label manual.
03. Chromis chrysura	3.593	1.175	Cluster spesies; label manual.
04. Amphiprion clarkii	4.049	1.021	Cluster spesies; label manual.
05. Chaetodon lunulatus	2.534	536	Cluster spesies; label manual.
06. Chaetodon trifascialis	190	79	Cluster spesies; label manual.
07. Myripristis kuntze	450	71	Cluster spesies; label manual.
08. Acanthurus nigrofuscus	218	71	Cluster spesies; label manual.
09. Hemigymnus fasciatus	241	58	Cluster spesies; label manual.

Kelas / cluster	Jumlah citra Detection #	Trajectory #	Penjelasan kelas
10. Neoniphon sammara	299	53	Cluster spesies; label manual.
11. Abudefduf vaigiensis	98	42	Cluster spesies; label manual.
12. Canthigaster valentini	147	28	Cluster spesies; label manual.
13. Pomacentrus moluccensis	181	27	Cluster spesies; label manual.
14. Zebrasoma scopas	90	23	Cluster spesies; label manual.
15. Hemigymnus melapterus	42	16	Cluster spesies; label manual.
16. Lutjanus fulvus	206	15	Cluster spesies; label manual.
17. Scolopsis bilineata	49	8	Cluster spesies; label manual.
18. Scaridae	56	5	Cluster spesies; label manual.
19. Pempheris vanicolensis	29	6	Cluster spesies; label manual.
20. Zanclus cornutus	21	6	Cluster spesies; label manual.
21. Neoglyphidodon nigroris	16	8	Cluster spesies; label manual.
22. Balistapus undulatus	41	6	Cluster spesies; label manual.
23. Siganus fuscescens	25	6	Cluster spesies; label manual.

Penjelasan kelas: seluruh kelas pada tabel adalah cluster spesies ikan yang diberi label manual berdasarkan ciri morfologi oleh anotator dengan panduan ahli biologi kelautan. Angka Detection # adalah jumlah citra ikan, sedangkan Trajectory # menunjukkan jumlah lintasan. Laman resmi menyatakan distribusi sangat tidak seimbang; kelas terbesar sekitar 1.000 kali kelas terkecil. Dataset ini tidak menyediakan label penyakit.

1.4.3. FishDisease / FlatIMG — deteksi lesi dan label patogen

Link dataset:

https://sites.google.com/view/cvl-jnu/publication/FishDisease/fishdisease_dataset.

Publikasi Hwang et al. (2025) dan laman Computer Vision Lab (n.d.)

menjelaskan FlatIMG sebagai kumpulan 1.861 foto terkait lesi dari 164 individu flatfish, dengan 394 kasus lesi unik dan 446 label lesi. Resolusi foto asli yang dilaporkan adalah 2048 x 1536 piksel. Dataset juga menyediakan citra asli, citra hasil generasi, anotasi bounding box lesi, serta label keberadaan dan tipe patogen. Tujuan utama dataset adalah mendeteksi lesi visual; label patogen tidak boleh dianggap sebagai bukti diagnosis klinis hanya dari gambar.

Tabel 1.5. Distribusi wilayah anotasi lesi pada FlatIMG

Kelas lokasi lesi	Jumlah	Penjelasan
Head / kepala	100	Kasus lesi unik pada area kepala.
Fins / sirip	178	Kasus lesi unik pada area sirip.
Body / tubuh	116	Kasus lesi unik pada area tubuh.
Total kasus lesi unik	394	Unit kasus; satu kasus dapat memiliki lebih dari satu label lesi.
Total label lesi	446	Instance label; jumlah dapat melebihi kasus unik karena multi-label.

Kelas lokasi pada tabel bukan kelas penyakit. Kelas tersebut menunjukkan bagian tubuh tempat lesi berada dan digunakan untuk membantu pelatihan lokalisasi. Beberapa label tipe lesi dapat berada pada satu wilayah yang sama.

Tabel 1.6. Label patogen pada berkas pathogens.zip

Kelompok	Kelas patogen	Record positif	Penjelasan
Bacteria	Streptococcus parauberis	40	Label patogen bakteri.
Bacteria	Vibrio scophthalmi	12	Label patogen bakteri; ejaan mengikuti arsip.
Bacteria	Vibrio harveyi	5	Label patogen bakteri.
Bacteria	Vibrio sinensis	1	Label patogen bakteri.
Bacteria	Vibrio tapetis	1	Label patogen bakteri.
Bacteria	Vibrio fischeri	1	Label patogen bakteri.
Bacteria	Edwardsiella tarda	4	Label patogen bakteri.
Bacteria	Edwardsiella piscicida	18	Label patogen bakteri.
Bacteria	Photobacterium damsela	10	Label patogen bakteri.
Bacteria	Lactococcus garvieae	1	Label patogen bakteri.
Viruses	Viral hemorrhagic septicemia virus	4	Label patogen virus.
Viruses	FHM, HINAE	2	Label kelompok virus sesuai arsip.

Kelompok	Kelas patogen	Record positif	Penjelasan
Parasites	Scuticociliates	37	Label kelompok parasit.
Parasites	Trichodinids	29	Label kelompok parasit.
Parasites	Skin Flukes	1	Label kelompok parasit.
Parasites	Ichthyobodo necator (Costia)	2	Label kelompok parasit.


Jumlah pada kolom Record positif dihitung dari 248 record pathogen.json pada arsip yang tersedia melalui laman dataset: 118 record memiliki setidaknya satu label positif dan 130 record tidak memiliki label positif. Karena label patogen bersifat multi-label, jumlah per kelas tidak boleh dijumlahkan untuk menyatakan jumlah citra. Kelompok Bacteria berarti label bakteri, Viruses berarti label virus, dan Parasites berarti label parasit; jenis patogen tetap diperlakukan sebagai anotasi dataset, bukan diagnosis otomatis.

Contoh visual dataset FishDisease



Sumber gambar: halaman FishDisease/FlatIMG yang diberikan; gambar menampilkan beberapa foto flatfish dari dataset.

Gambar 1.4. Contoh foto flatfish pada FishDisease/FlatIMG



Sumber gambar: halaman FishDisease/FlatIMG yang diberikan; anotasi visual dan kotak lesi dipertahankan sebagai contoh format lokalisasi.

Gambar 1.5. Contoh citra flatfish dengan penanda area lesi

1.4.4. Freshwater Fish Disease — Kaggle

Link dataset:

<https://www.kaggle.com/datasets/subirbiswas19/freshwater-fish-disease-aquaculture-in-south-asia/data>.


Pemilik dataset adalah SUBIR BISWAS. Laman Kaggle meminta pengguna mencantumkan Biswas et al. (2024) bila dataset digunakan. Versi yang tampil pada halaman Kaggle adalah versi 4, berukuran 25,99 MB, berlisensi CC0 Public Domain, dan ringkasannya mencatat 2.451 file: 2.228 JPG, 58 PNG, 158 JPEG, dan 7 file lain. Data dikumpulkan dari departemen pertanian universitas, pertanian/kolam di Odisha, India dengan bantuan ahli, serta portal pertanian. Resolusi piksel tidak dicantumkan pada data card Kaggle, sehingga resolusi final harus dicatat dari metadata file setelah dataset diunduh; dokumen ini tidak mengarang satu resolusi tetap.

Tabel 1.7. Kelas penyakit pada dataset Kaggle

Kelas	Jumlah menurut deskripsi	Penjelasan kelas
Bacterial diseases - Aeromoniasis	250	Label infeksi bakteri; pada citra dapat tampak sebagai kemerahan, luka, atau perdarahan.
Bacterial gill disease	250	Label penyakit bakteri pada insang; perhatian visual diarahkan pada perubahan/kerusakan insang.
Bacterial Red disease	250	Label penyakit bakteri dengan ciri visual kemerahan atau perdarahan pada permukaan tubuh.
Fungal diseases - Saprolegniasis	250	Label infeksi jamur/oomycete; sering diasosiasikan dengan pertumbuhan putih seperti kapas.
Healthy Fish	250	Ikan tanpa tanda penyakit yang terlihat pada citra; bukan jaminan kondisi klinis.
Parasitic diseases	250	Label kelompok penyakit parasit; dapat terlihat sebagai iritasi, bintik, lendir, atau lesi.
Viral diseases White tail disease	250	Label visual white-tail; digunakan sebagai kelas citra dan tidak menetapkan patogen tanpa pemeriksaan tambahan.

Catatan jumlah: deskripsi Kaggle menyebut 250 citra untuk masing-masing dari 7 kelas, sehingga angka yang tertulis per kelas

berjumlah 1.750. Namun, ringkasan file versi 4 menunjukkan 2.451 file dengan rincian ekstensi di atas. Perbedaan ini harus diverifikasi setelah file final diunduh karena ringkasan file dapat mencakup CSV atau file pendukung. Penjelasan biologis pada tabel adalah interpretasi nama kelas untuk kebutuhan computer vision, bukan definisi diagnosis resmi dari Kaggle. Dataset ini cocok untuk klasifikasi tingkat gambar; tanpa bounding box, model tidak boleh mengklaim menemukan lokasi lesi.



Sumber: disusun oleh penulis berdasarkan Fish4Knowledge (2013), Fish Recognition Ground-Truth data, CVL FishDisease Dataset (Hwang et al., 2025), dan dataset Freshwater Fish Disease dari Kaggle.

Gambar 1.6. Alur pemanfaatan Fish4Knowledge dan dua dataset penyakit ikan

Rancangan pengolahan data

1. Fish4Knowledge: gunakan image dan mask untuk memperoleh bounding box ikan. Jika data berasal dari video atau trajectory yang sama, pembagian train, validation, dan test dilakukan berdasarkan trajectory atau sumber video, bukan secara acak per frame, untuk mengurangi data leakage.
2. FishDisease: pasangkan citra dengan berkas anotasi lesi dan label patogen, lalu konversi bounding box ke format YOLO jika diperlukan. Pisahkan data berdasarkan ikan atau sumber pengambilan, bukan hanya secara acak per gambar. Citra generasi harus ditandai terpisah saat evaluasi agar hasil tidak terlalu optimistis.
3. Freshwater Fish Disease (Kaggle): periksa nama folder, jumlah kelas, duplikasi, dan distribusi setiap kelas. Gunakan pembagian stratified serta catat versi dataset yang digunakan.

Jika tidak tersedia bounding box, gunakan dataset ini untuk klasifikasi, bukan sebagai label lokasi lesi.

4. Preprocessing citra: resize dengan rasio yang terjaga, padding bila perlu, normalisasi, dan augmentasi moderat seperti perubahan brightness, contrast, blur ringan, atau flip yang masih masuk akal bagi objek ikan.
5. Skema label: Fish4Knowledge digunakan untuk kelas fish; FishDisease digunakan untuk bounding box lesi dan label patogen; dataset Kaggle digunakan untuk kelas penyakit pada tingkat citra. Prediksi kelas penyakit tidak boleh disebut sebagai lokasi lesi jika tidak didukung bounding box.
6. Pelatihan yang disarankan: latih atau fine-tune YOLO26 + DAM untuk lokalisasi ikan dan/atau lesi pada data beranotasi, lalu gunakan YOLO26-cls + DAM untuk klasifikasi multi-kelas pada crop ikan dari dataset Kaggle. Bandingkan hasilnya dengan YOLO26 baseline tanpa DAM dan laporkan evaluasi per dataset.

Metrik evaluasi yang sesuai adalah mAP@50-95, precision, recall, dan latency/FPS untuk deteksi ikan atau lesi; serta accuracy, macro precision, macro recall, macro F1, dan confusion matrix untuk klasifikasi multi-kelas penyakit. Untuk label patogen, tambahkan evaluasi per tipe patogen dan multilabel metric bila satu citra dapat memiliki lebih dari satu label. Karena dokumen ini merupakan rancangan awal, belum ada angka hasil eksperimen yang boleh dilaporkan sebagai hasil penelitian.

DAFTAR PUSTAKA

- Biswas, S. (n.d.) Freshwater Fish Disease Aquaculture in South Asia [Dataset]. Kaggle. Available at: <https://www.kaggle.com/datasets/subirbiswas19/freshwater-fish-disease-aquaculture-in-south-asia/data> (Accessed: 30 August 2026).
- Biswas, S., Muduli, D., Islam, M.A., Kanade, A.S., Zamani, A.T., Kanade, S.P. and Parveen, N. (2024) 'Empirical Evaluation of Deep Learning Techniques for Fish Disease Detection in Aquaculture Systems: A Transfer Learning and Fusion-Based Approach', IEEE Access, 12, pp. 176136–176154. Available at: <https://doi.org/10.1109/ACCESS.2024.3504283>.
- Bochkovskiy, A., Wang, C.Y. and Liao, H.Y.M. (2020) 'YOLOv4: Optimal Speed and Accuracy of Object Detection', arXiv preprint arXiv:2004.10934. Available at: <https://arxiv.org/abs/2004.10934>.
- Computer Vision Lab, Chonnam National University (n.d.) FishDisease Dataset: Flatfish Image Dataset [Dataset]. Available at: https://sites.google.com/view/cvl-jnu/publication/FishDisease/fishdisease_dataset (Accessed: 30 August 2026).
- Dai, X., Chen, Y., Xiao, B., Chen, D., Liu, M., Yuan, L. and Zhang, L. (2021) 'Dynamic Head: Unifying Object Detection Heads With Attention', Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 7373–7382. Available at: <https://doi.org/10.1109/CVPR46437.2021.00727>.
- Fisher, R.B., Chen-Burger, Y.H., Giordano, D., Hardman, L. and Lin, F.P. (eds.) (2016) Collecting and Analyzing Massive Coral Reef Fish Video Data. Cham: Springer. Available at: <https://doi.org/10.1007/978-3-319-30208-9>.
- Fish4Knowledge (2013) Fish4Knowledge Project. University of Edinburgh. Available at: <https://homepages.inf.ed.ac.uk/rbf/fish4knowledge/> (Accessed: 30 August 2026).
- Fish4Knowledge (n.d.) Fish Recognition Ground-Truth data. University of Edinburgh. Available at: <https://homepages.inf.ed.ac.uk/rbf/Fish4Knowledge/GROUNDTRUTH/RECOG/> (Accessed: 30 August 2026).
- Hwang, S.-B., Kim, H.-Y., Heo, C.-Y., Jeong, H.-Y., Jung, S.-J. and Cho, Y.-J. (2025) 'Flatfish lesion detection based on part segmentation approach and lesion image generation', Journal of the World Aquaculture Society, 56(3), e70031. Available at: <https://doi.org/10.1111/jwas.70031>.
- Jocher, G., Qiu, J., Liu, M., Lyu, S., Akyon, F.C. and Kalfaoglu, M.E. (2026) 'Ultralytics YOLO26: Unified Real-Time End-to-End Vision Models', arXiv preprint arXiv:2606.03748. Available at: <https://doi.org/10.48550/arXiv.2606.03748>.

- Li, C. et al. (2022) 'YOLOv6: A Single-Stage Object Detection Framework for Industrial Applications', arXiv preprint arXiv:2209.02976. Available at: <https://doi.org/10.48550/arXiv.2209.02976>.
- Redmon, J., Divvala, S., Girshick, R. and Farhadi, A. (2016) 'You Only Look Once: Unified, Real-Time Object Detection', Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pp. 779–788. Available at: <https://doi.org/10.1109/CVPR.2016.91>.
- Redmon, J. and Farhadi, A. (2017) 'YOLO9000: Better, Faster, Stronger', Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pp. 7263–7271. Available at: <https://doi.org/10.1109/CVPR.2017.690>.
- Redmon, J. and Farhadi, A. (2018) 'YOLOv3: An Incremental Improvement', arXiv preprint arXiv:1804.02767. Available at: <https://arxiv.org/abs/1804.02767>.
- Ultralytics (2020) Ultralytics YOLOv5, software repository, version 7.0. Available at: <https://github.com/ultralytics/yolov5> and <https://doi.org/10.5281/zenodo.3908559>.
- Ultralytics (2023) Explore Ultralytics YOLOv8. Available at: <https://docs.ultralytics.com/models/yolov8/> (Accessed: 30 August 2026).
- Ultralytics (2024) Ultralytics YOLO11. Available at: <https://docs.ultralytics.com/models/yolo11/> (Accessed: 30 August 2026).
- Ultralytics (2025) YOLO12: Attention-Centric Object Detection. Available at: <https://docs.ultralytics.com/models/yolo12/> (Accessed: 30 August 2026).
- Ultralytics (2026) Ultralytics YOLO26. Available at: <https://docs.ultralytics.com/models/yolo26/> (Accessed: 30 August 2026).
- Wang, A., Chen, H., Liu, L., Chen, K., Lin, Z., Han, J. and Ding, G. (2024a) 'YOLOv10: Real-Time End-to-End Object Detection', arXiv preprint arXiv:2405.14458. Available at: <https://doi.org/10.48550/arXiv.2405.14458>.
- Wang, C.Y., Bochkovskiy, A. and Liao, H.Y.M. (2023) 'YOLOv7: Trainable Bag-of-Freebies Sets New State-of-the-Art for Real-Time Object Detectors', Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Available at: <https://doi.org/10.1109/CVPR52729.2023.00721>.
- Wang, C.Y., Yeh, I.H. and Liao, H.Y.M. (2024b) 'YOLOv9: Learning What You Want to Learn Using Programmable Gradient Information', arXiv preprint arXiv:2402.13616. Available at: <https://doi.org/10.48550/arXiv.2402.13616>.